

Uncertainty Quantification in Machine Learning

Wen, Zehai

2026-06-21 20:31:08-04:00

Contents

1	Assignment 1 Faite le 7 février 2024 date limite le 8 février 2024	2
----------	---	----------

Chapter 1

Assignment 1 Faite le 7 février 2024 date limite le 8 février 2024

Remarque Toutes les références dans ce document sont tirées de notre note de cours ou des tables des distributions si le contraire n'est pas explicitement mentionné.

Exercice 1

Soit $X = (X_1, \dots, X_n)$ un échantillon de $P_\theta = \text{Bernoulli}(\theta)$. Le paramètre $\theta \in [0, 1]$ est inconnu. Fixer un niveau $\alpha \in (0, 1)$. On écrit $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ et $c(\theta)$ pour la plus petite nombre $k \in \{0, \dots, n\}$ telle que $P_\theta \{X_1 + \dots + X_n \leq k\} \geq 1 - \alpha$. On construit trois régions de confiances suivantes pour θ :

$$R_1(X) = \left\{ \theta \in [0, 1] \mid \bar{X} - \theta \leq z_\alpha \sqrt{\frac{\theta(1-\theta)}{n}} \right\}$$

$$R_2(X) = \left\{ \theta \in [0, 1] \mid \bar{X} - \theta \leq z_\alpha \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \right\}$$

$$R_3(X) = \{ \theta \in [0, 1] \mid n\bar{X} \leq c(\theta) \}$$

Ici $z_\alpha \in \mathbb{R}$ est choisie telle que $P \{Z \leq z_\alpha\} = 1 - \alpha$, où Z est une variable aléatoire qui suit la loi normale centrée réduite.

Complétez les tâches suivantes :

1. Tracez $c(\theta)$ pour les $\theta \in \{\frac{i}{M}\}_{i=0}^M$.
2. Démontrez que $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \bar{x}(1 - \bar{x})$ si $x_i \in \{0, 1\}$ pour $i \in \{1, \dots, n\}$. Ici $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.
3. Étant donné X , résolvez pour θ dans $R_1(X)$, $R_2(X)$ et $R_3(X)$. Concluez que toutes les trois régions sont intervalles.
4. Pour $k \in \{1, 2, 3\}$, calculez et tracez $P_\theta \{ \theta \in R_k \}$ pour les $\theta \in \{\frac{i}{M}\}_{i=0}^M$.

Utilisez $n = 30$, $\alpha = 0.1$ et $M = 1000$ pour toutes les simulations.

Solution On fait les démonstrations avant les simulations. D'abord, soit $x_i \in \{0, 1\}$ pour $i \in \{1, \dots, n\}$. On a $x_i^2 = x_i$ pour tout i et :

$$\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2) = \bar{x} - \bar{x}^2 = \bar{x}(1 - \bar{x})$$

Étant observé $X = (x_1, \dots, x_n)$, on donne les formes explicites pour les trois régions. $R_1(X)$ donne une inégalité quadratique. Il faut résoudre d'abord $\bar{x} - \theta = \frac{z_\alpha}{\sqrt{n}} \sqrt{\theta(1 - \theta)}$. Les racines sont :

$$\theta = \frac{2n\bar{x} + z_\alpha^2 \pm \sqrt{z_\alpha^4 + 4nz_\alpha^2\bar{x} - 4nz_\alpha^2\bar{x}^2}}{2(n + z_\alpha^2)}$$

L'existence de ces racines dépend sur la valeur de $\bar{x}$, alors un autre quadratique. Les racines sont :

$$\bar{x} = \frac{n \pm \sqrt{n^2 + z_\alpha^2 n}}{2n}$$

Alors, les racines de θ existe si $\bar{x} \in \left[\frac{n - \sqrt{n^2 + z_\alpha^2 n}}{2n}, \frac{n + \sqrt{n^2 + z_\alpha^2 n}}{2n} \right] \supset [0, 1]$. Un regard aux graphes des fonctions

$\bar{x} - \theta$ et $\frac{z_\alpha}{\sqrt{n}} \sqrt{\theta(1 - \theta)}$ montre que ces deux fonctions se croise deux fois si et seulement si $\bar{x} \in \left[1, \frac{n + \sqrt{n^2 + z_\alpha^2 n}}{2n} \right]$,

et se croise exactement une fois quand $\theta = \frac{2n\bar{x} + z_\alpha^2 - \sqrt{z_\alpha^4 + 4nz_\alpha^2\bar{x} - 4nz_\alpha^2\bar{x}^2}}{2(n + z_\alpha^2)}$ sinon. Alors :

$$R_1(X) = \begin{cases} [0, 1] & \bar{X} \leq 0 \\ \left[\frac{2n\bar{x} + z_\alpha^2 - \sqrt{z_\alpha^4 + 4nz_\alpha^2\bar{x} - 4nz_\alpha^2\bar{x}^2}}{2(n + z_\alpha^2)}, 1 \right] & \bar{X} \in [0, 1] \\ \left[\frac{2n\bar{x} + z_\alpha^2 - \sqrt{z_\alpha^4 + 4nz_\alpha^2\bar{x} - 4nz_\alpha^2\bar{x}^2}}{2(n + z_\alpha^2)}, \frac{2n\bar{x} + z_\alpha^2 + \sqrt{z_\alpha^4 + 4nz_\alpha^2\bar{x} - 4nz_\alpha^2\bar{x}^2}}{2(n + z_\alpha^2)} \right] & \bar{X} \in \left[1, \frac{n + \sqrt{n^2 + z_\alpha^2 n}}{2n} \right] \\ \emptyset & \bar{X} > \frac{n + \sqrt{n^2 + z_\alpha^2 n}}{2n} \end{cases}$$

Ensuite, $R_2(X)$ est bien définie pour seulement $\bar{x} \in [0, 1]$. Si $\bar{x} \in [0, 1]$, on a :

$$R_2(X) = \left[\max \left\{ 0, \bar{X} - z_\alpha \sqrt{\frac{\bar{X}(1 - \bar{X})}{n}} \right\}, 1 \right]$$

On se concentre, à partir de maintenant, sur $R_3(X)$. Fixer un niveau $\alpha \in (0, 1)$. Afin de trouver et inverser $c(\theta)$, on doit représenter cette définition discrète par une fonction spéciale. On utilise la fonction bêta incomplète régularisée :

$$I_x(a, b) = \frac{B(x; a, b)}{B(a, b)} = \frac{\int_0^x t^{a-1}(1-t)^{b-1} dt}{\int_0^1 t^{a-1}(1-t)^{b-1} dt}$$

Ici $x \in [0, 1]$ et $a, b > 0$. Pour a et b fixés, $I_x(a, b)$ est une fonction continue et strictement croissante de x . On a alors une inverse continue et strictement croissante $I_y^{-1}(a, b)$ pour tout y dans l'image telle que $y = I_{I_y^{-1}(a, b)}(a, b)$. La somme $X_1 + \dots + X_n$ suit la loi binomiale $B(n, \theta)$. Utilisant la fonction bêta incomplète régularisée, on peut représenter la fonction de répartition de cette distribution.

Pour tout $k \in \{0, \dots, n\}$, on a :

$$P_\theta \{X_1 + \dots + X_n \leq k\} = \sum_{m=0}^k \binom{n}{m} \theta^m (1 - \theta)^{n-m} = I_{1-\theta}(n - k, k + 1)$$

On remarque que cette formule démontre que $I_\theta(n - k, k + 1)$ est croissante en nombres entiers k pour tout $\theta \in [0, 1]$ fixé. On démontre un lemme, qui va être utile plus tard.

Lemme 1. Fixer un $v \in (0, 1)$. La fonction $I_v^{-1}(n - k, k + 1)$ est décroissant en nombres entiers $k \in \{0, \dots, n\}$.

Proof. Soit k_1 et $k_2 \in \{0, \dots, n\}$ telle que $k_1 \leq k_2$. Écrire $y_1 = I_v^{-1}(n - k_1, k_1 + 1)$ et $y_2 = I_v^{-1}(n - k_2, k_2 + 1)$. En raison de croissance monotone de k :

$$I_{y_2}(n - k_2, k_2 + 1) = v = I_{y_1}(n - k_1, k_1 + 1) \leq I_{y_1}(n - k_2, k_2 + 1)$$

La croissance monotone de x dans les fonctions $I_x(a, b)$ implique que $y_1 \geq y_2$. $\square$

Retournons au problème principal. Si $y \leq 0$, on a $c(\theta) \geq y$ pour tout $\theta \in [0, 1]$. Si $y > n$, on a $c(\theta) \geq y$ pour aucun $\theta \in [0, 1]$. Si $y \in \{1, \dots, n\}$, on a $c(\theta) \geq y$ si et seulement si $I_{1-\alpha}(n - k, k + 1) \geq 1 - \alpha$ pour tout $k \in \{y, y + 1, \dots, n\}$ et $I_{1-\alpha}(n - y + 1, y) < 1 - \alpha$. Si on utilise la première condition avec $k = y$, on a, selon la croissance monotone de la fonction inverse :

$$\theta \leq 1 - I_{1-\alpha}^{-1}(n - y, y + 1)$$

Le lemme montre que cette borne supérieure est la plus petite borne supérieure possible. Similairement, on a :

$$\theta > 1 - I_{1-\alpha}^{-1}(n - y + 1, y)$$

Finalement, l'observation $\{\theta \in [0, 1] \mid c(\theta) \geq y\} = \{\theta \in [0, 1] \mid c(\theta) \geq \lceil y \rceil\}$ pour tout $y \in \mathbb{R}$ va résoudre le cas général. On conclut que :

$$R_3(X) = \begin{cases} [0, 1] & \overline{X} \leq 0 \\ \emptyset & \overline{X} > 1 \\ (1 - I_{1-\alpha}^{-1}(n - \lceil n\overline{X} \rceil + 1, \lceil n\overline{X} \rceil), 1 - I_{1-\alpha}^{-1}(n - \lceil n\overline{X} \rceil, \lceil n\overline{X} \rceil + 1)) & \text{sinon} \end{cases}$$

On voudrait aussi calculer les probabilités de couverture exacte $P_\theta \{\theta \in R_k(X)\}$ pour les trois régions. Écrire, pour tout $x \in \mathbb{R}$, que $h(x) = \chi_{[0, n+1)}(x)[x] + n\chi_{[n+1, \infty)}(x)$. Il est immédiat que :

$$P_\theta \{\theta \in R_1(X)\} = \sum_{i=0}^{h(n\theta + z_\alpha \sqrt{n\theta(1-\theta)})} \binom{n}{i} \theta^i (1 - \theta)^{n-i}; \quad P_\theta \{\theta \in R_3(X)\} = \sum_{i=0}^{c(\theta)} \binom{n}{i} \theta^i (1 - \theta)^{n-i}$$

Pour trouver $P_\theta \{\theta \in R_2(X)\}$, il faut d'abord résoudre l'équation $\overline{X} - \theta = z_\alpha \sqrt{\frac{\overline{X}(1-\overline{X})}{n}}$. La solution est :

$$\overline{x} = \frac{2n\theta + z_\alpha^2 \pm \sqrt{z_\alpha^4 + 4nz_\alpha^2\theta - 4nz_\alpha^2\theta^2}}{2(n + z_\alpha^2)}$$

Comme $\theta \in [0, 1]$, cette solution existe toujours. Un regard aux graphes des fonctions $\overline{x} - \theta$ et $z_\alpha \sqrt{\frac{\overline{x}(1-\overline{x})}{n}}$ montre que ces deux fonctions se croise deux fois si et seulement si $\theta = 0$ et se croise exactement une fois à $\overline{x} = \frac{2n\theta + z_\alpha^2 + \sqrt{z_\alpha^4 + 4nz_\alpha^2\theta - 4nz_\alpha^2\theta^2}}{2(n + z_\alpha^2)}$ sinon. Alors, $\theta \in R_2(X)$ si et seulement si $\overline{X} \in \left[0, \frac{2n\theta + z_\alpha^2 + \sqrt{z_\alpha^4 + 4nz_\alpha^2\theta - 4nz_\alpha^2\theta^2}}{2(n + z_\alpha^2)}\right]$.

On obtient que :

$$P_\theta \{\theta \in R_2(X)\} = \sum_{i=0}^{h\left(\frac{2n\theta + z_\alpha^2 + \sqrt{z_\alpha^4 + 4nz_\alpha^2\theta - 4nz_\alpha^2\theta^2}}{2(n + z_\alpha^2)}\right)} \binom{n}{i} \theta^i (1 - \theta)^{n-i}$$

Les démonstrations sont complètes. On trace des fonctions importantes. D'abord, on trace $c(\theta)$ pour les $\theta \in \left\{\frac{i}{M}\right\}_{i=0}^M$.


```
library(ggplot2)

n <- 30
alpha <- 0.1
M <- 1000
theta_values <- seq(0, 1, length.out = M+1)

c_theta <- function(theta) {
  for (k in 0:n) {
    if (pbinom(k, n, theta) >= 1 - alpha) {
      return(k)
    }
  }
  return(n)
}

c_values <- sapply(theta_values, c_theta)
p <- ggplot(data.frame(theta = theta_values, c = c_values), aes(x = theta, y =
  c)) +
  geom_line() +
  show(p)
```

Le résultat est :



Ensuite, on trace $P_\theta \{\theta \in R_k\}$ pour les $\theta \in \{\frac{i}{M}\}_{i=0}^M$ et pour chaque $k \in \{1, 2, 3\}$. Le code R le plus inefficace

est comme suivant :

```

h <- function(num){
  if (num >= n) {
    return (n)
  }
  else {
    return(floor(num))
  }
}

R_1_borne <- function(theta){
  return (h(n*theta + qnorm(1-alpha)*sqrt(n*theta*(1-theta))))
}

R_1_bornes <- sapply(theta_values, R_1_borne)

R_3_borne <- function(theta){
  z_alpha <- qnorm(1-alpha)
  return (h(2*n*theta + z_alpha^2 + sqrt(z_alpha^4 + 4*n*theta*(z_alpha^2)-
    4*n*(theta*z_alpha)^2)/(2*n+2*z_alpha^2)))
}

R_3_bornes <- sapply(theta_values, R_3_borne)

prob_couverture <- matrix(0, nrow = 3, ncol = length(theta_values))
for (i in seq_along(theta_values)){
  theta <- theta_values[i]
  for (j in 0: R_1_bornes[i]){
    prob_couverture[1, i] <- prob_couverture[1, i] + dbinom(j, n, theta)
  }
  for (j in 0: c_values[i]){
    prob_couverture[2, i] <- prob_couverture[2, i] + dbinom(j, n, theta)
  }
  for (j in 0: R_3_bornes[i]){
    prob_couverture[3, i] <- prob_couverture[3, i] + dbinom(j, n, theta)
  }
}

data_to_plot <- data.frame(
  Theta = rep(theta_values, times = 3),
  Coverage = c(prob_couverture[1, ], prob_couverture[2, ], prob_couverture[3, ]),
  Interval = rep(c("R1", "R2", "R3"), each = length(theta_values))
)

p <- ggplot(data_to_plot, aes(x = Theta, y = Coverage, color = Interval)) +
  geom_line() +
  labs(title = "Probabilité de couverture exacte pour différents intervalles de
    confiance",
    x = "", y = "Probabilité de couverture exacte") +
  theme_minimal() + labs(color = " ") +
  theme(legend.position = "top")+
  geom_abline(intercept = 0.9, slope = 0, color="black")

```

```
show(p)
```

On fait aussi une simulation générant 500 fois jeu de données pour chaque $\theta \in \{\frac{i}{M}\}_{i=0}^M$.

```
check_in_R_1 <- function(theta, x_bar){
  if (x_bar - theta <= qnorm(1 - alpha / 2)*sqrt(theta*(1-theta)/n)){
    return (1)
  }
  else{
    return(0) }
}

check_in_R_2 <- function(theta, x_bar){
  if (x_bar - theta <= qnorm(1 - alpha / 2)*sqrt(x_bar*(1-x_bar)/n)){
    return (1)
  }
  else{
    return(0) }
}

check_in_R_3 <- function(theta, x_bar){
  if (n*x_bar <= c_theta(theta)){
    return (1)
  }
  else{
    return(0) }
}

simulation <- function(num_simulations = 500){
  coverage_prob <- matrix(0, nrow = 3, ncol = length(theta_values))
  for (i in seq_along(theta_values)){
    theta <- theta_values[i]
    coverage <- c(R1 = 0, R2 = 0, R3 = 0)
    for (sim in 1:num_simulations) {
      samples <- rbinom(n, size = 1, prob = theta)
      x_bar <- mean(samples)
      coverage["R1"] <- coverage["R1"] + check_in_R_1(theta, x_bar)
      coverage["R2"] <- coverage["R2"] + check_in_R_2(theta, x_bar)
      coverage["R3"] <- coverage["R3"] + check_in_R_3(theta, x_bar)
    }
    coverage_prob[1, i] <- coverage["R1"] / num_simulations
    coverage_prob[2, i] <- coverage["R2"] / num_simulations
    coverage_prob[3, i] <- coverage["R3"] / num_simulations
  }
  return(coverage_prob)
}

coverage <- simulation()

data_to_plot <- data.frame(
  Theta = rep(theta_values, times = 3),
  Coverage = c(coverage[1, ], coverage[2, ], coverage[3, ]),
```





```
Interval = rep(c("R1", "R2", "R3"), each = length(theta_values))
)

p <- ggplot(data_to_plot, aes(x = Theta, y = Coverage, color = Interval)) +
  geom_line() +
  labs(title = "Probabilités de couverture Simulées pour différents intervalles de
    confiance",
    x = "", y = "Probabilité de couverture Simulé") +
  theme_minimal() + labs(color = " ") +
  theme(legend.position = "top")+
  geom_abline(intercept = 0.9, slope = 0, color="black")

show(p)
```

Les résultats sont :





Alors, dans la théorie ou dans la simulation, parmi les valeurs de θ , c'est plus souvent que R_1 ou R_3 est le plus proche de niveau de confiance nominale $1 - \alpha$. Le phénomène de zigzag est aussi observé dans la simulation. ////

Exercice 2

Soit X_1 et X_2 un échantillon de taille 2 de $P_\theta = \text{Uniform}(0, \theta)$. Le paramètre $\theta > 0$ est inconnu. Écrire $Y = \frac{X_1 + X_2}{2}$. Étant observé X_1 et X_2 , on construit un intervalle de confiance pour θ de niveau $1 - \alpha = 0.9$ sous la forme $[aY, bY]$ pour $a, b \in \mathbb{R}$. Trouvez a et b telle que la longueur de l'intervalle soit minimale.

Solution Toutes les densités sont par rapport à la mesure de Lebesgue en $\mathbb{R}$. Évidemment, $\frac{1}{\theta}(X_1 + X_2)$ est une somme de deux variables aléatoires indépendantes de loi $\text{Uniform}(0, 1)$. Sa densité h est donnée par :

$$h(z) = \int_{\mathbb{R}} \chi_{(0,1)}(x) \chi_{(0,1)}(x - z) dx = m((z - 1, z) \cap (0, 1)) = z \chi_{(0,1)}(z) + (2 - z) \chi_{(1,2)}(z)$$

Écrire f pour la densité de $\frac{\theta}{Y}$. Alors :

$$f(z) = \frac{4}{z^3} \chi_{(2,\infty)}(z) + \left(\frac{4}{z^2} - \frac{4}{z^3} \right) \chi_{(1,2)}(z)$$

Supposons que $P_\theta \{ \theta \in [aY, bY] \} = 1 - \alpha$ pour des nombres $a, b \in \mathbb{R}$, où $\alpha = 0.1$. Comme :

$$\int_2^\infty \frac{4}{z^3} dz = \int_1^2 \left(\frac{4}{z^2} - \frac{4}{z^3} \right) dz = \frac{1}{2}$$

Il faut minimiser $b - a$ pour $1 \leq a \leq 2 \leq b$ sous la contrainte :

$$1 - \alpha = \int_a^b f(z) dz = \int_a^2 \left(\frac{4}{z^2} - \frac{4}{z^3} \right) dz + \int_2^b \frac{4}{z^3} dz$$

Après de résoudre des intégraux, on obtient la contrainte simplifiée :

$$\frac{4}{a} - \frac{2}{a^2} - 2 + \alpha - \frac{2}{b^2} = 0$$

On multiplie $a^2 b^2$ des deux côtés et on obtient :

$$[(\alpha - 2)a^2 + 4a - 2]b^2 = 2a^2$$

Comme $(\alpha - 2)a^2 + 4a - 2 > 0$ quand $a \in (\frac{2 - \sqrt{2\alpha}}{2 - \alpha}, \frac{2 + \sqrt{2\alpha}}{2 - \alpha})$, on réduit la contrainte de a à $[1, 2] \cap (\frac{2 - \sqrt{2\alpha}}{2 - \alpha}, \frac{2 + \sqrt{2\alpha}}{2 - \alpha})$. Quand $\alpha = 0.1$, cela donne effectivement $a \in [1, 1.288007156)$. Si a est dans cet intervalle, on a :

$$b = a \sqrt{\frac{2}{(\alpha - 2)a^2 + 4a - 2}}$$

On définit une fonction $g : [1, 2] \cap (\frac{2 - \sqrt{2\alpha}}{2 - \alpha}, \frac{2 + \sqrt{2\alpha}}{2 - \alpha}) \rightarrow \mathbb{R}$ par :

$$g(a) = a \sqrt{\frac{2}{(\alpha - 2)a^2 + 4a - 2}} - a$$

Comme g est continue, soit a_0 le minimum de g . L'intervalle de longueur minimale est alors $[a_0 Y, b_0 Y]$ où $b_0 = a_0 \sqrt{\frac{2}{(\alpha - 2)a_0^2 + 4a_0 - 2}}$. Malheureusement, a_0 n'a pas de forme analytique. On poursuit en R avec $\alpha = 0.1$ pour obtenir une approximation numérique :

```
alpha <- 0.05
intervalle <- c(max(1, ((2-sqrt(2*alpha))/(2-alpha))), min(2,
  ((2+sqrt(2*alpha))/(2-alpha))))

g <- function(a){
  return (sqrt(2)*a/sqrt((alpha-2)*a**2+4*a-2) - a)
}

a_0 <- optimize(f = g, interval = intervalle)$minimum
b_0 <- g(a_0) + a_0

print(c(a_0,b_0))
print(b_0-a_0)
```

La réponse est :

```
[1] 1.011526 4.477954
[1] 3.466428
```

Alors, si $\alpha = 0.1$, le choix optimal est approximativement $a_0 = 1.011526$ et $b_0 = 4.477954$. ///